



회귀 Regression

머신러닝/딥러닝

임 경 태

Week	Chapter	Contents
1	1, 2장	강의 소개, 파이썬 복습
2	1, 3장	파이썬 복습, Numpy, Pandas
3	1, 4장	딥러닝을 위한 미분
4	5장	회귀
5	5장	분류
6	6장	XOR문제
7	7장	딥러닝
8	1~7장	중간고사
9	8장	MNIST 필기체 구현 (팀 프로젝트)
10	9장	오차역전파
11	11장	합성곱 신경망(CNN)
12	12장	순환 신경망(RNN)
13	10장	자율주행 (Collision Avoidance, Transfer Learning)
14	11장	자율주행 (Load Following)
15	8~12장	기말고사 (or 프로젝트 발표)

CONTENTS

—

① 머신 러닝 개요

② 선형 회귀

③ 경사 하강법



목적 : 지도학습의 대표적인 알고리즘인 선형회귀에 대한 학습



목표 : 선형 회귀와 경사 하강법에 대한 이해



내용 : 머신 러닝 개요, 선형 회귀, 경사 하강법

CONTENTS

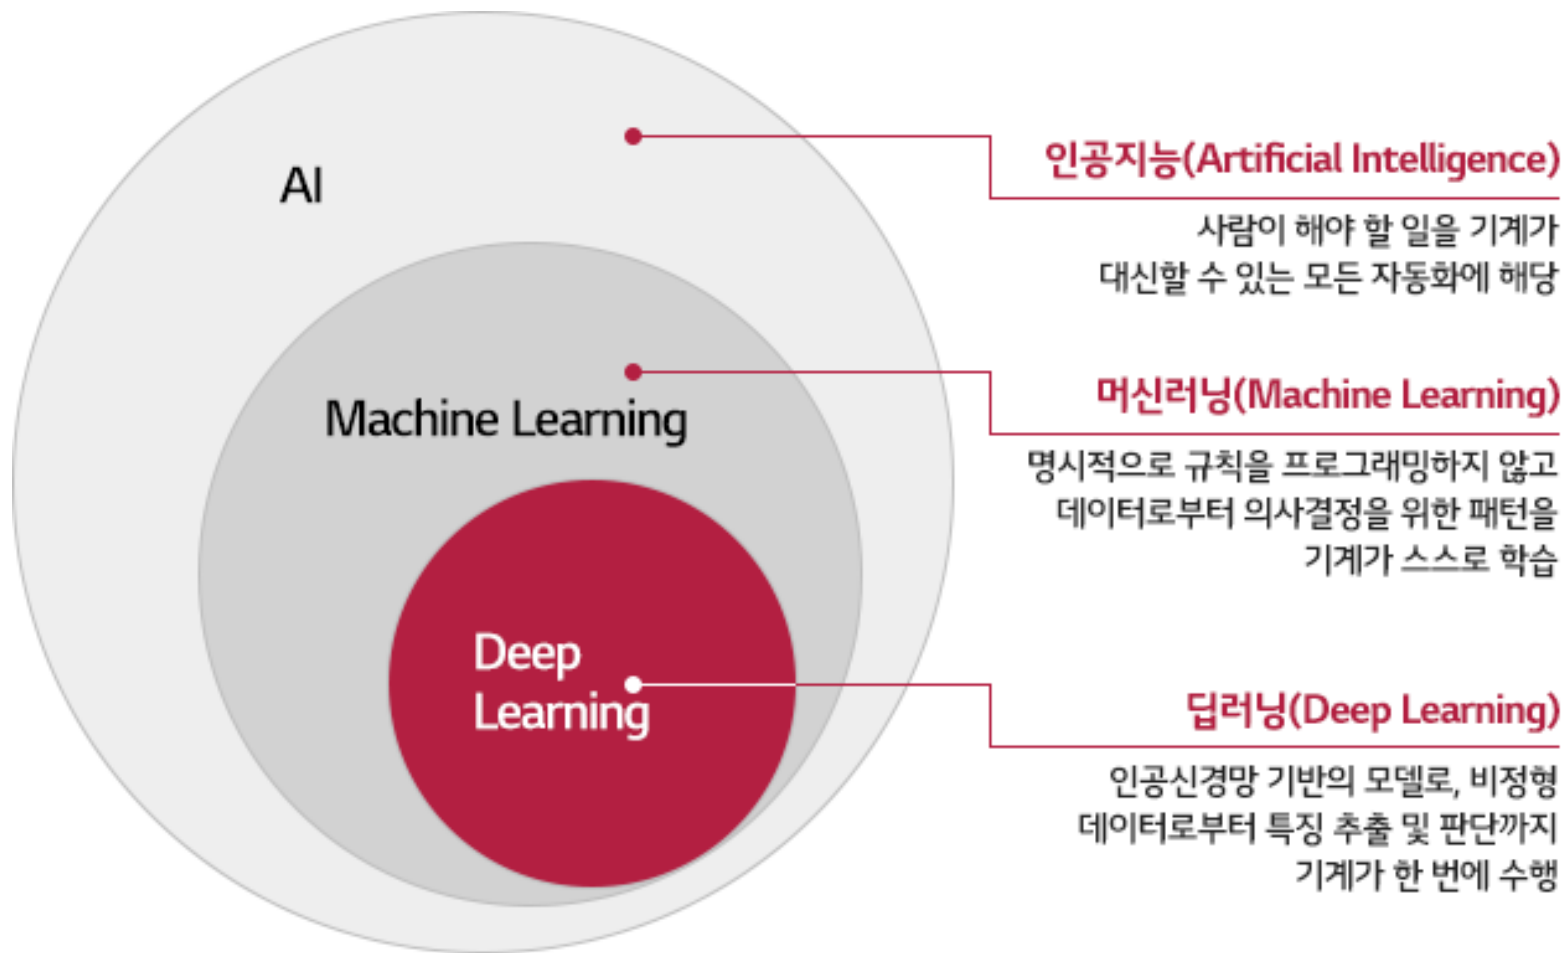
—

① 머신 러닝 개요

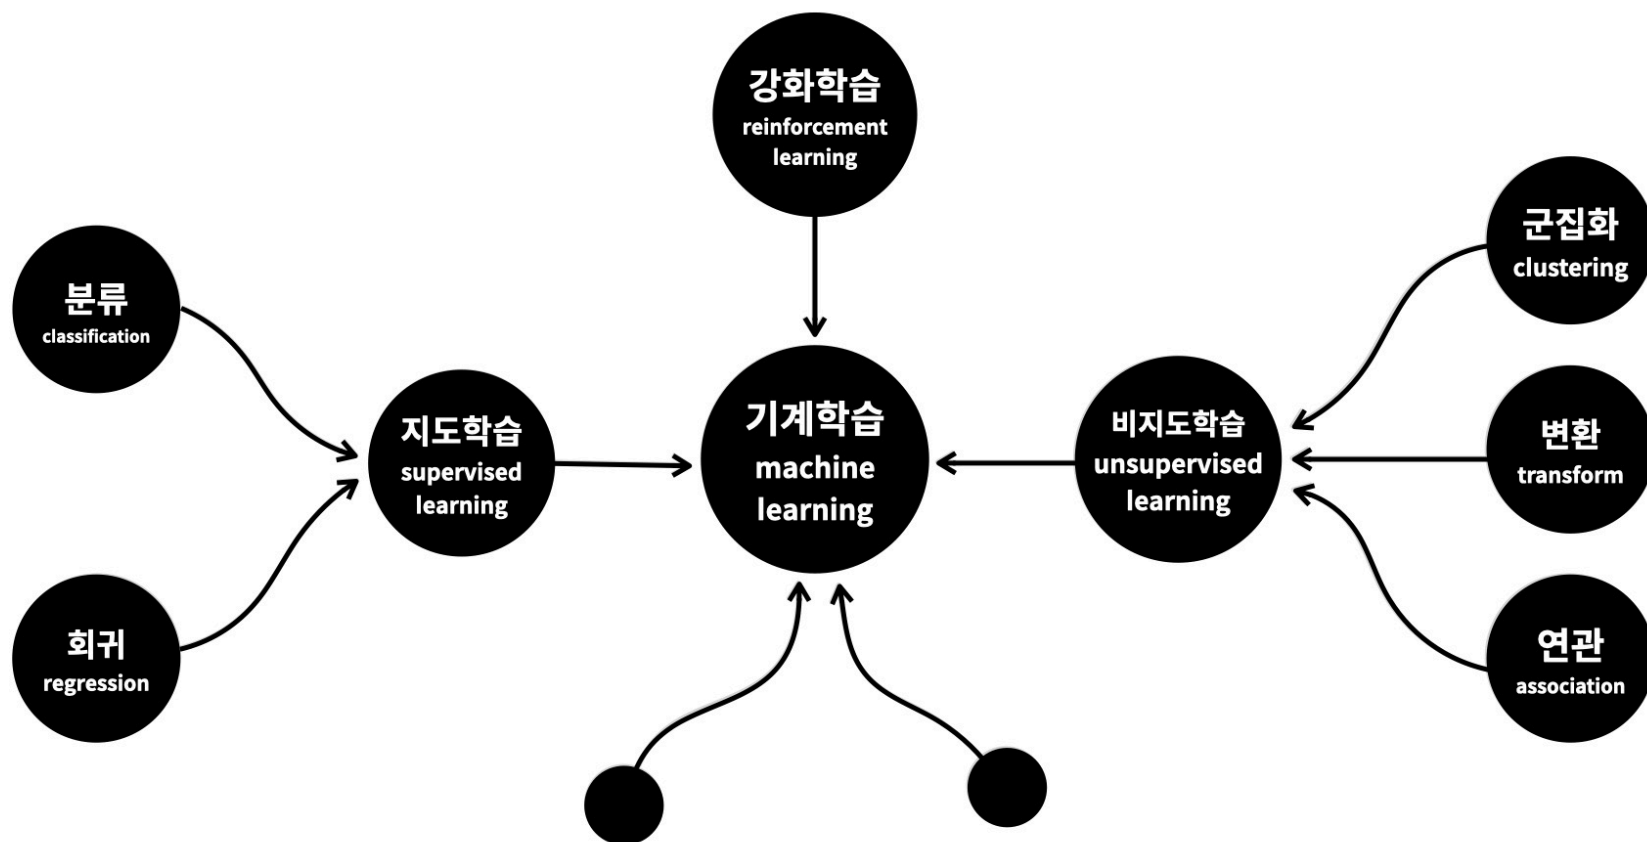
② 선형 회귀

③ 경사 하강법

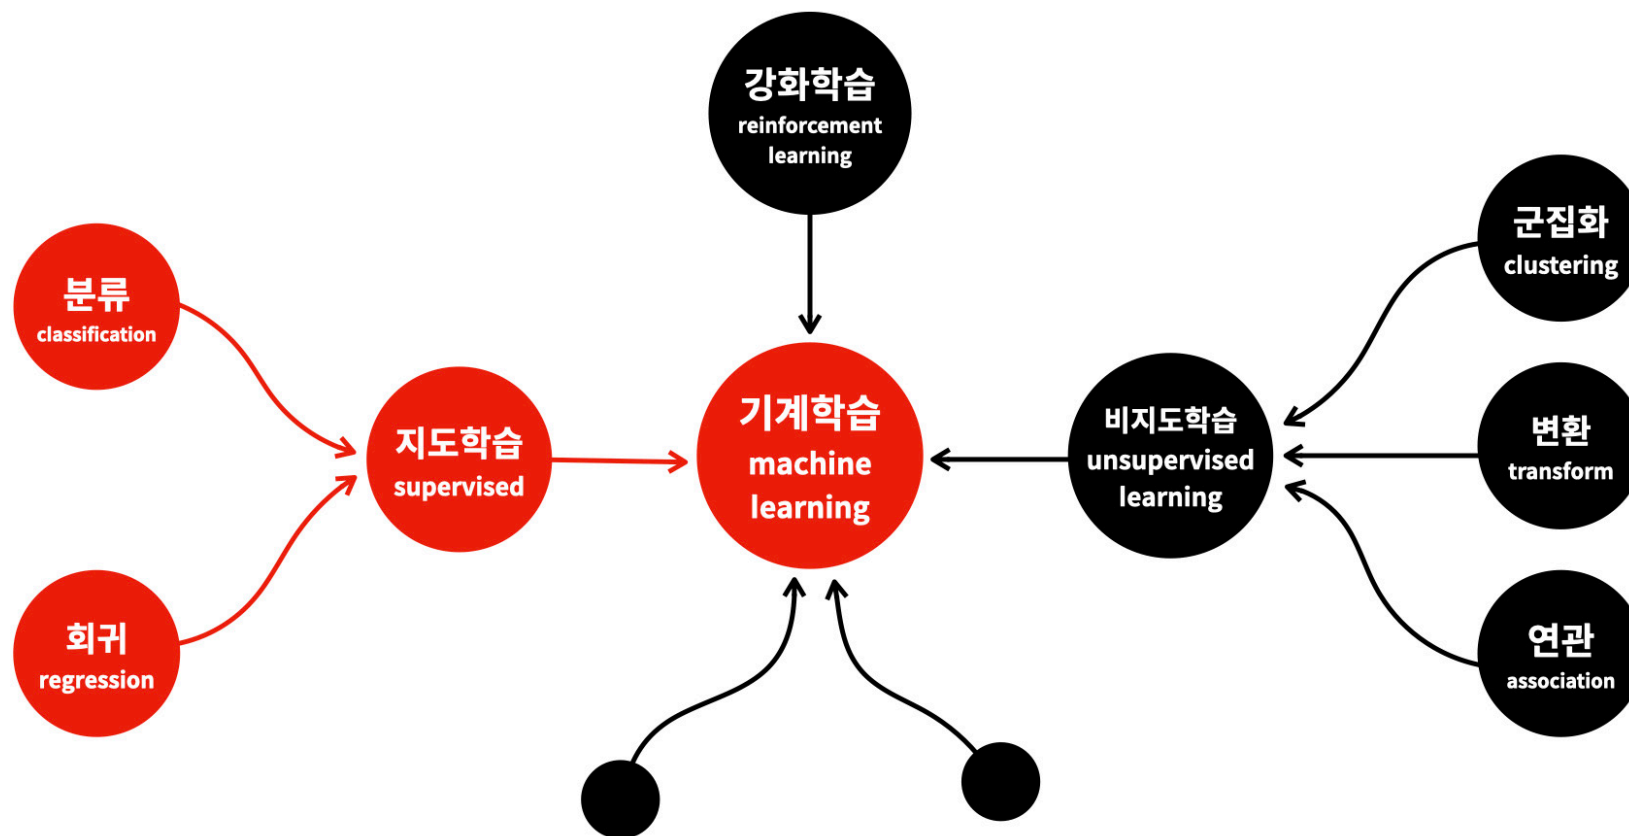
머신 러닝 개요



머신 러닝 개요



머신 러닝 개요



- 머신 러닝은 크게 지도학습, 비지도학습, 강화학습의 세 가지로 정답 label 존재 여부, 학습 방법 등을 기준으로 나뉜다.
- 회귀와 분류는 정답 label이 존재하는 데이터를 학습하는 알고리즘으로 지도학습에 속한다.

CONTENTS

① 머신 러닝 개요

② 선형 회귀

③ 경사 하강법

선형 회귀

- 회귀는 주어진 데이터를 통해 미지의 데이터를 연속적인 값으로 예측하는 알고리즘으로 일반적으로 여러 개의 입력을 갖는다.

간단한 회귀 예제 (입력이 한 개)

- 공부시간 → 시험 성적
- 1인당 GDP → 삶의 만족도 등

선형 회귀

- 선형회귀모델 : 출력변수 Y 를 입력변수 X 들의 선형결합으로 표현한 모델

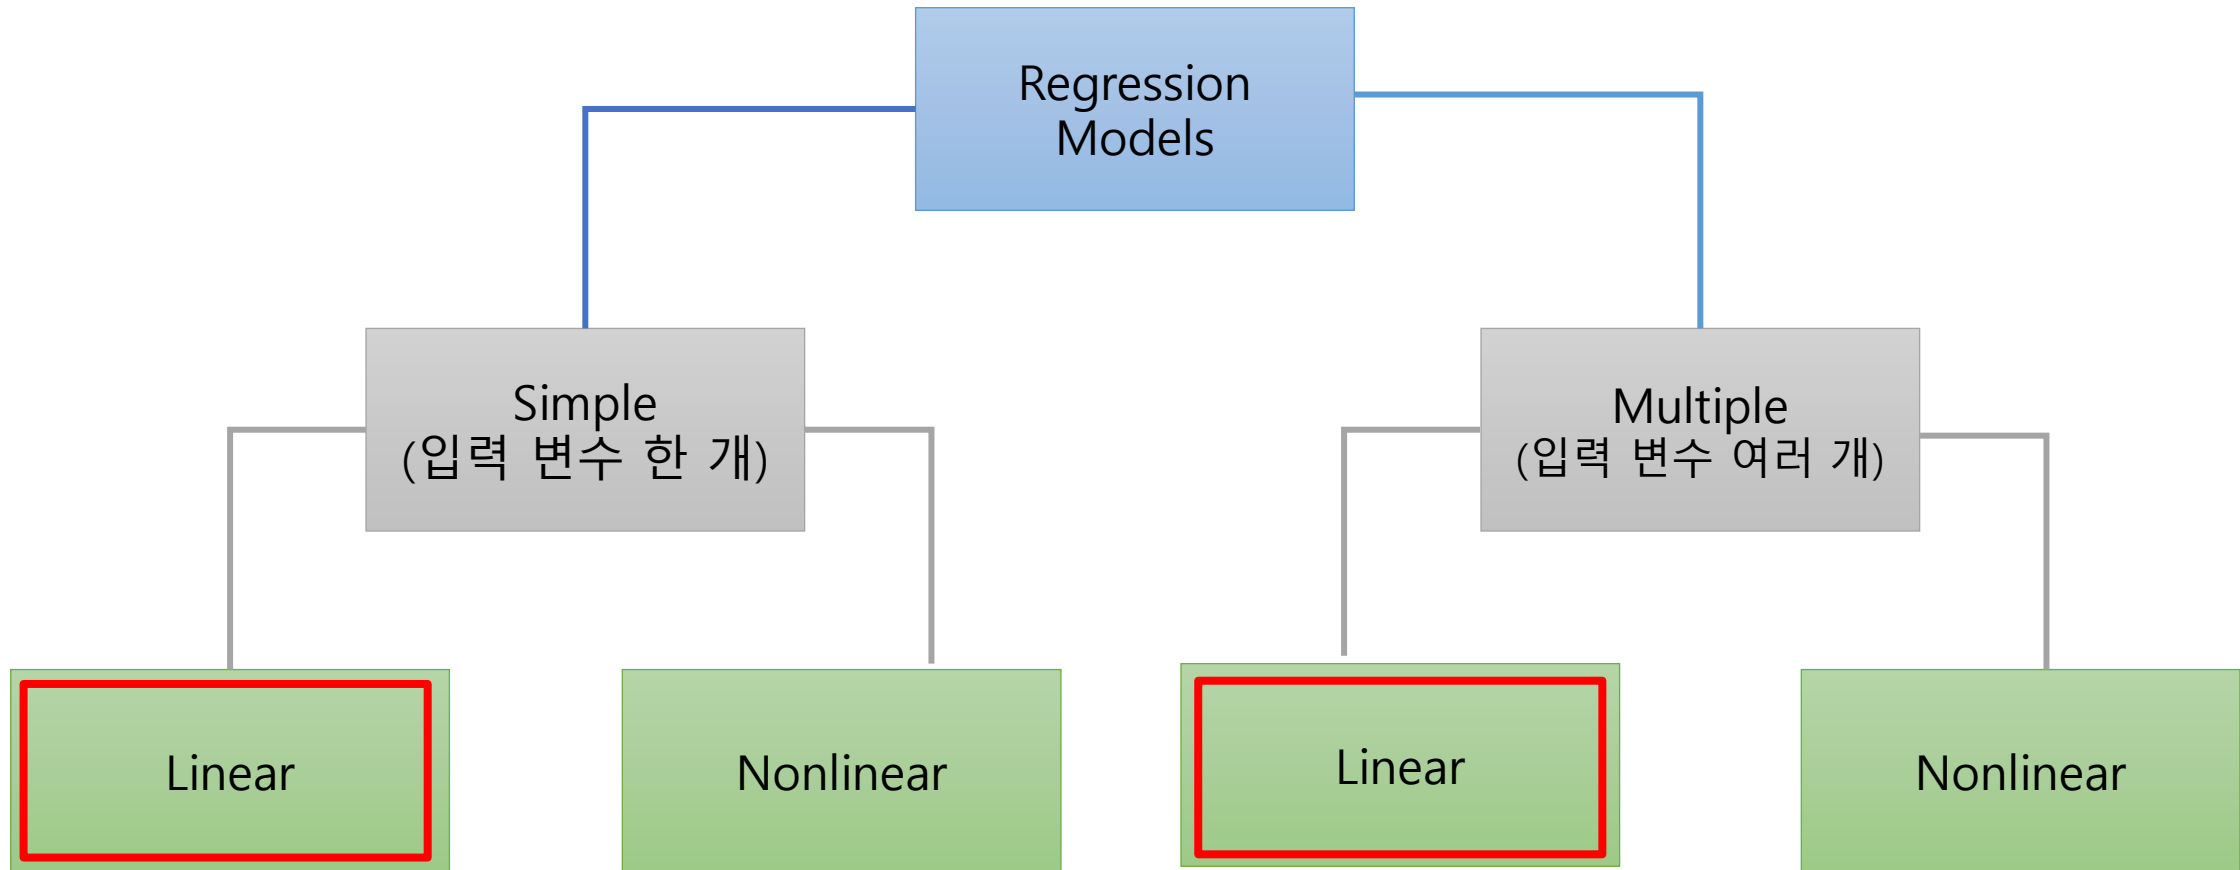
- 선형 결합 : 변수들을 상수 배, 덧셈을 통해 결합

ex) $w_0 + w_1x_1 + w_2x_2 + w_3x_3 + \cdots + w_nx_n$

w_i : 상수, x_i : 변수

특히 w_0 는 편향이라고 하며 $b(\text{bias})$ 로 표현함.

선형 회귀

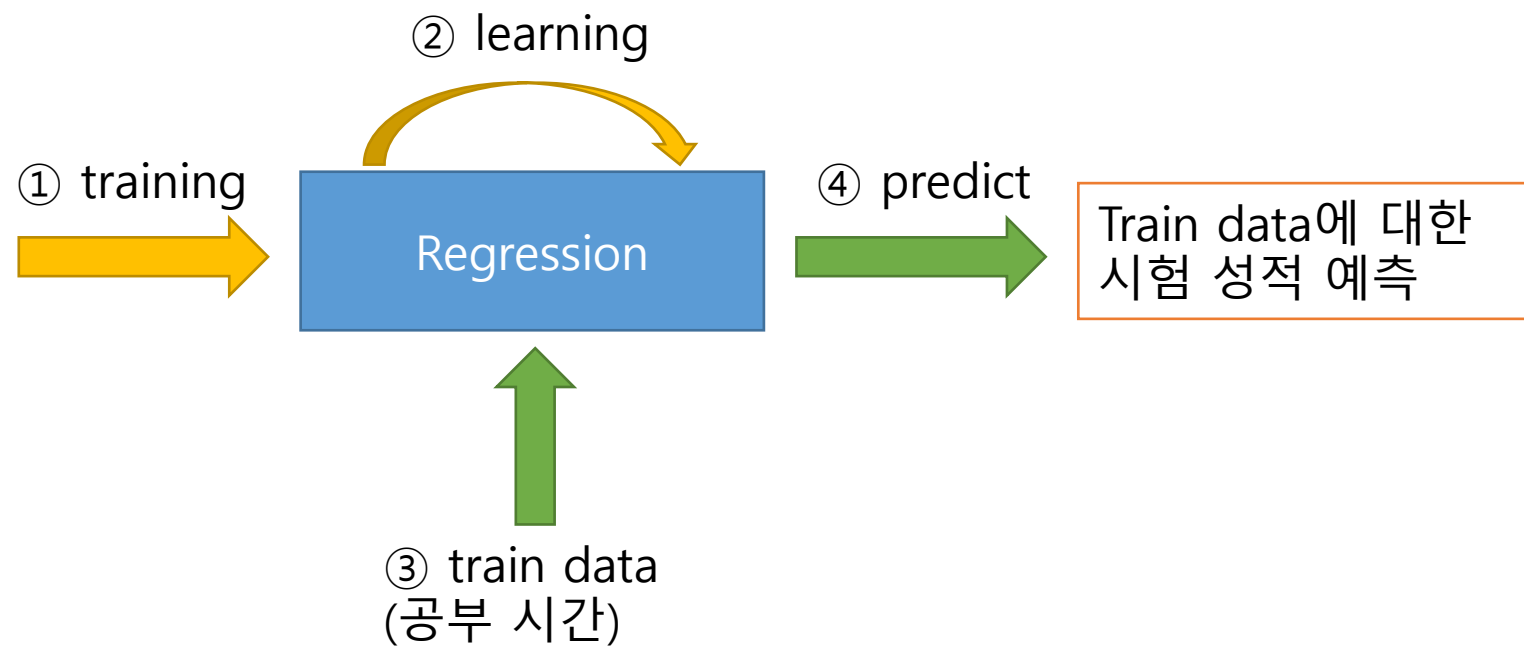


- $\hat{y} = \mathbf{w}\mathbf{x} + \mathbf{b}$
 - y 예측 값 (교재에서는 t 로 표현)
- $\mathbf{w} = [w_1 \ w_2 \ w_3 \ \cdots]^T$
 - 가중치 벡터, 학습을 통해 최적값을 구함
- $\mathbf{x} = [x_1 \ x_2 \ x_3 \ \cdots]$
 - 특성 벡터
- \mathbf{b}
 - 편향

선형 회귀 Simple, Linear 예제

공부 시간 → 시험 성적 예제

이름	수학 공부시간	점수
야쓰오	2	3
오공	4	4
블리츠	6	5
페이커	8	6



선형 회귀 Simple, Linear 예제

DATA

이름	수학 공부시간	점수
야쓰오	2	3
오공	4	4
블리츠	6	5
페이커	8	6



Find w and b



Predict \hat{y}


x : 공부 시간, y : 시험 성적

\hat{y} : 미지의 공부시간에 대해 예측한 시험 성적

선형 회귀 Simple, Linear 예제

□ 선형회귀 평가

- 관측된 표본데이터와 우리가 선택한 w, b 값으로 생성한 직선을 비교해 차이가 적은 w, b 값을 찾자



어떤 평가척도를 사용해서 w, b 를 평가할까?

- 관측된 표본(x_1, y_1)과 f_1 과의 편차 = $(f_1(x_1) - y_1) = 1.2$
- 전체 편차의 합 = $\sum_{i=1} (f_1(x_i) - y_i) = 0$??
- 전체 편차의 평균 = $1/n * \sum_{i=1} (f_1(x_i) - y_i) = 0$??
- 편차 제곱의 평균 = $1/n * \sum_{i=1} (f_1(x_i) - y_i)^2 = 0.8$

loss function (MSE, Mean Square Error)

- $MSE = \frac{1}{n} \sum_{i=1}^n ((wx^{(i)} + b) - y^{(i)})^2$
 $= \frac{1}{n} \sum_{i=1}^n (\widehat{y^{(i)}} - y^{(i)})^2$

- $\widehat{y^{(i)}}$: 예측한 결과

- $y^{(i)}$: 정답

- MSE를 최소로 하는 것이 목표 → 경사 하강법

선형 회귀 multiple, Linear 예제

- $f(\text{평수, 위치, 방의 개수,}\dots) \rightarrow \text{집값 예측}$
- $f(\text{나이, 흡연 기간, 가족력,}\dots) \rightarrow \text{폐암 예측}$
- $f(\text{성별, 나이, 수영 여부,}\dots) \rightarrow \text{생존 가능성 예측}$
- $f(\text{강우량, 일조량, 지형,}\dots) \rightarrow \text{농작물 가격 예측}$

CONTENTS

① 머신 러닝 개요

② 선형 회귀

③ 경사 하강법

경사 하강법 (Gradient Descent)

- 최적의 매개변수(w)를 찾기 위한 알고리즘

최적의 매개변수란 손실함수를 최소로 만드는 매개변수

보통 매개변수 공간이 광대하여 어디에서 손실함수가 최소가 되는지 짐작 불가능

→ 기울기(gradient)를 이용하여 손실함수의 최솟값을 찾음

경사 하강법 (Gradient Descent)

복습 – Gradient

- Gradient란 최대의 증가율을 나타내는 벡터.
- Gradient가 최대의 증가율을 나타내기 때문에 Gradient의 반대방향을 따라가면 Local minimum에 가장 빠르게 도달한다.
- 즉 벡터 $\nabla f(x, y, z) = \left\langle \frac{\partial f(x, y, z)}{\partial x}, \frac{\partial f(x, y, z)}{\partial y}, \frac{\partial f(x, y, z)}{\partial z} \right\rangle$ 는 $f(x, y, z)$ 에서 가장 가파른 방향을 나타냄.

경사 하강법 (Gradient Descent)

- 경사 하강법


- 임의의 가중치 w 를 선택 (random)

- 선택된 w 에서의 기울기 $\frac{\partial E}{\partial w}$ 를 구함

(여기서 E 는 loss function, $\frac{\partial E}{\partial w}$ 는 w 가 변할 때 E 의 변화량을 의미)

- 미분 값 $\frac{\partial E}{\partial w}$ 가 작아지는 방향으로 w 를 업데이트하면 local minimum에 도달

Simple, Linear 예제의 w , $E(w)$ 그래프




[그림 5.12] 경사하강법(Gradient Descent Algorithm) 원리

□ Gradient Descent Algorithm


- 미분을 이용해 cost값이 작아지는 방향으로 조금씩 w값을 업데이트 하자!!

$$W := W - \alpha \frac{\partial}{\partial W} cost(W)$$



$$\underset{W, b}{\text{minimize}} cost(W, b)$$

$$cost(W) = \frac{1}{m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2$$



경사 하강법 (Gradient Descent)

- 경사 하강법 공식

$$w \leftarrow w - \alpha \frac{\partial E}{\partial w}$$

α : 학습률 (learning rate), 한 번의 학습으로 얼마만큼 매개변수 값을 갱신할지 결정

$-\alpha \frac{\partial E}{\partial w}$: gradient의 반대방향으로 학습



감사합니다.